

UNIVERSIDADE PRESBITERIANA MACKENZIE
CURSO DE TECNOLOGIA EM CIÊNCIA DE DADOS

ANDERSON APARECIDO DA SILVA ALVES
ANDRÉIA DOMINGOS DOS SANTOS
GERSON SOARES RODRIGUES
SAMUEL BONFIM DA SILVA

RA:

10347602

10288503

10423804

10423569

RECONHECIMENTO DE FRUTAS POR MEIO DE REDES
NEURAIS CONVOLUCIONAIS COM APLICAÇÃO EM SISTEMA
DE RECOMENDAÇÃO ATRAVÉS DAS INFORMAÇÕES
NUTRICIONAIS

SÃO PAULO

2025

**ANDERSON APARECIDO DA SILVA ALVES
ANDRÉIA DOMINGOS DOS SANTOS
GERSON SOARES RODRIGUES
SAMUEL BONFIM DA SILVA**

**RECONHECIMENTO DE FRUTAS POR MEIO DE REDES NEURAIS
CONVOLUCIONAIS COM APLICAÇÃO EM SISTEMA DE RECOMENDAÇÃO
ATRAVÉS DAS INFORMAÇÕES NUTRICIONAIS**

Frutfy: Conheça, Compare e Diversifique sua Alimentação com Frutas

Trabalho acadêmico para conclusão da
disciplina de Projeto Aplicado III do Curso de
Tecnologia em Ciência de Dados pela
Universidade Presbiteriana Mackenzie.

Professor: Carolina Toledo Ferraz

**SÃO PAULO
2025**

A001

Silva, Anderson Aparecido da Silva.

Dos Santos, Andréia Domingos.

Rodrigues, Gerson Soares.

Da Silva, Samuel Bonfim.

Sistema de Recomendação de frutas por CNN e
Recomendação através das informações nutricionais /
Anderson Aparecido da Silva Alves; Andréia Domingos dos
Santos; Gerson Soares Rodrigues; Samuel Bonfim da Silva -
2025. 9f.: il.; 30 cm.

Trabalho Acadêmico (Projeto Aplicado III) – Universidade
Presbiteriana Mackenzie,

SUMÁRIO

Frutfy: Conheça, Compare e Diversifique sua Alimentação com Frutas	i
1. INTRODUÇÃO	1
1.1 Contexto do trabalho	1
1.2 Motivação	1
1.3 Justificativa	1
1.4 Objetivo	1
1.4.1 Objetivo Geral	1
1.4.2 Objetivos Específicos:	1
2. REFERENCIAL TEÓRICO	2
3. METODOLOGIA	3
3.1 Coleta e Organização dos Dados	3
3.2 Pré-processamento das Imagens	3
3.3 Arquitetura do Modelo e Ajustes	3
3.4 Sistema de Recomendação Nutricional	3
3.5 Avaliação e Refinamento:	4
3.6 Organização do Pipeline	4
3.7 Interface e API	4
3.8 Contribuição do Grupo:	4
4. RESULTADOS ESPERADOS E AVALIAÇÃO	4
5. LINK PARA O ACESSO DO PROJETO NO GITHUB	5
6. REFERÊNCIA BIBLIOGRÁFICA	5

1. INTRODUÇÃO

1.1 CONTEXTO DO TRABALHO

A alimentação saudável é essencial para a qualidade de vida, mas muitas pessoas ainda enfrentam dificuldade para acessar informações nutricionais confiáveis sobre os alimentos. Paralelamente, o avanço da inteligência artificial abre espaço para soluções tecnológicas que otimizam o acesso a dados alimentares e incentivam escolhas mais saudáveis.

1.2 MOTIVAÇÃO

O reconhecimento automatizado de frutas pode contribuir para setores como o comércio, a logística e a saúde, além de promover educação alimentar. A possibilidade de integrar redes neurais convolucionais (CNN) a um sistema de recomendação nutricional oferece um recurso inovador para promover a diversificação alimentar personalizada.

1.3 JUSTIFICATIVA

A grande semelhança visual entre frutas e as variações de ambiente desafiam a classificação manual, o que justifica o uso de CNNs. Este projeto não só automatiza o reconhecimento de frutas como também orienta escolhas alimentares com base em dados nutricionais confiáveis, apoiando os Objetivos de Desenvolvimento Sustentável (ODS 2, 3 e 12).

1.4 OBJETIVO

1.4.1 *Objetivo Geral*

- Desenvolver uma plataforma que reconheça frutas a partir de imagens e forneça recomendações de frutas nutricionalmente similares.

1.4.2 *Objetivos Específicos:*

- Realizar o treinamento de modelo CNN com Transfer Learning (ResNet50) para reconhecimento de frutas.
- Coletar e organizar um banco de dados nutricional com informações sobre diversas frutas.
- Implementar algoritmo de recomendação baseado em distância euclidiana entre perfis nutricionais.
- Validar o sistema com métricas como acurácia, precisão, recall e F1-score.
- Desenvolver uma interface web intuitiva para upload de imagem ou pesquisa textual.

2. REFERENCIAL TEÓRICO

O projeto se fundamenta em dois pilares principais: visão computacional e sistemas de recomendação.

No campo da visão computacional, o reconhecimento de imagens por meio de Redes Neurais Convolucionais (RNCs) tem se mostrado altamente eficiente em tarefas como classificação de imagens, OCR e análise de espectrogramas. Segundo *Priscila Mello Alves (2020)*, as RNCs são uma subarquitetura do Deep Learning com elevada capacidade de reconhecimento de padrões complexos, especialmente em contextos supervisionados. Elas aprendem com exemplos de treinamento e extraem automaticamente características relevantes das imagens, o que elimina a necessidade de engenharia manual de atributos e melhora o desempenho de sistemas preditivos.

Entre as arquiteturas mais utilizadas, destaca-se a ResNet50, projetada com blocos residuais que possibilitam a construção de redes profundas sem sofrer com o problema da degradação de desempenho (*Vinagreiro, 2022*). Conforme demonstrado por *Majumder (2023)*, o uso da ResNet50 com Transfer Learning permite o reaproveitamento de características visuais aprendidas previamente em grandes bases de dados, como o ImageNet. Isso contribui para uma significativa redução no tempo de treinamento e melhora a acurácia, mesmo quando se dispõe de conjuntos de dados menores. Essa abordagem também facilita a adaptação do modelo a novas tarefas, como exemplificado na classificação do conjunto de dados CIFAR-10 utilizando a biblioteca Keras. Para tornar o modelo acessível e interativo, o uso do *Gradio (2023)* é recomendado, uma vez que a ferramenta permite criar interfaces web amigáveis, possibilitando que qualquer pessoa utilize o modelo diretamente em seu navegador.

No segundo pilar do projeto, os sistemas de recomendação são implementados com base em algoritmos baseados em conteúdo, ideais quando se deseja sugerir itens com propriedades semelhantes. Neste caso, a recomendação de frutas será realizada com base na similaridade entre seus perfis nutricionais, utilizando a distância euclidiana como métrica de comparação (*Scikit-learn, 2023*).

As informações nutricionais utilizadas na construção dos vetores de atributos são provenientes de bases de dados confiáveis e atualizadas, como a Tabela Brasileira de Composição de Alimentos – *TBCA (2023)* e a FoodData Central do U.S. Department of Agriculture – *USDA (2023)*, garantindo a precisão e qualidade dos dados utilizados.

Por fim, a implementação computacional do projeto utiliza bibliotecas amplamente adotadas no meio científico: PyTorch, para o treinamento da CNN; Pandas e NumPy, para manipulação e análise de dados; além do Flask, que é empregado na construção da API que integra as funcionalidades do sistema.

3. METODOLOGIA

A metodologia do projeto Frutfy foi estruturada com base nas diretrizes da terceira etapa do Projeto Aplicado III, incluindo o refinamento do modelo, a sistematização de técnicas e a avaliação de desempenho. A abordagem seguiu uma linha lógica e incremental, como será descrito a seguir:

3.1 COLETA E ORGANIZAÇÃO DOS DADOS

Inicialmente, foram reunidas 6.664 imagens de 30 tipos de frutas distintas, provenientes de bases públicas. Essas imagens foram separadas em conjuntos de treino (4.652), validação (986) e teste (1.026), respeitando a distribuição de 70/15/15. Constatou-se uma variação na quantidade de amostras por classe, o que exigiu atenção no balanceamento durante o treinamento.

3.2 PRÉ-PROCESSAMENTO DAS IMAGENS

As imagens passaram por um processo de padronização, incluindo:

- Redimensionamento para 224x224 pixels.
 - Conversão em tensores normalizados.
 - Adoção de técnicas para preparação compatível com a arquitetura ResNet50.
- Esses passos garantiram estabilidade no treinamento e contribuíram para a generalização do modelo.

3.3 ARQUITETURA DO MODELO E AJUSTES

Foi utilizada a ResNet50 com Transfer Learning. As camadas iniciais foram congeladas até o penúltimo bloco, e adicionou-se uma camada densa com 30 neurônios e ativação softmax. A configuração adotada incluiu:

- Otimizador Adam.
- Função de perda CrossEntropyLoss.
- 10 épocas de treinamento.
- Taxa de aprendizado: 0.001.

3.4 SISTEMA DE RECOMENDAÇÃO NUTRICIONAL

Foi implementado um mecanismo de recomendação baseado em similaridade entre frutas, utilizando atributos nutricionais coletados da TBCA e USDA. A comparação foi realizada com a distância euclidiana aplicada sobre vetores contendo calorias, fibras, açúcares, entre outros.

3.5 AVALIAÇÃO E REFINAMENTO:

Os resultados iniciais indicaram acurácia de 93% e F1-score macro de 0.92. Contudo, frutas como manga e pêssgo tiveram desempenhos inferiores. Para refinar o modelo, aplicou-se data augmentation (espelhamento, brilho, rotação e zoom), e considerou-se a possibilidade de testar novas arquiteturas como MobileNetV2.

3.6 ORGANIZAÇÃO DO PIPELINE

O pipeline foi representado por meio de um fluxograma, evidenciando os seguintes passos:

- Entrada de imagem → Pré-processamento → Classificação com CNN → Resultado + Chamada da Recomendação Nutricional → Exibição via Interface.

3.7 INTERFACE E API

A API foi construída com Flask, permitindo o envio de imagens e retorno da previsão e recomendação. A interface web foi elaborada com uso do Gradio, tornando o sistema acessível.

3.8 CONTRIBUIÇÃO DO GRUPO:

Cada membro contribuiu em etapas específicas: coleta e limpeza dos dados, modelagem da CNN, validação das recomendações, desenvolvimento da API e testes. A cooperação contínua permitiu superar desafios como o desbalanceamento das classes e a otimização do tempo de resposta do sistema.

4. RESULTADOS ESPERADOS E AVALIAÇÃO

Espera-se que o sistema Frutty atinja alta performance tanto na tarefa de classificação quanto na recomendação nutricional. A meta é manter acurácia superior a 90% e garantir sugestões coerentes com os perfis nutricionais.

A avaliação será conduzida com base em:

- **Classificação:** métricas como acurácia, precisão, recall e F1-score.
- **Recomendação:** avaliação qualitativa e verificação da proximidade nutricional entre frutas sugeridas.
- **Interface:** testes de usabilidade para garantir acessibilidade e praticidade no uso da ferramenta.

Com os ajustes realizados, o projeto visa consolidar um sistema funcional, inovador e com potencial de aplicação prática na promoção de uma alimentação mais saudável e personalizada.

5. LINK PARA O ACESSO DO PROJETO NO GITHUB

<https://github.com/grupos4g4/PROJEAPLIC3/tree/main>

6. REFERÊNCIA BIBLIOGRÁFICA

1. ALVES, Priscila Mello. "Inteligência artificial e redes neurais." IPEA: Centro de Pesquisa em Ciência (2020). Disponível em: <https://www.ipea.gov.br/cts/pt/central-de-conteudo/artigos/artigos/106-inteligencia-artificial-e-redes-neurais>. Acesso em: 02 abr. 2025.
2. VINAGREIRO, Michel Andre Lima. **Classificação baseada em espaços de camadas convolucionais de redes CNNs densas**. Repositório Universidade de São Paulo, 2022. Disponível em: <https://repositorio.usp.br/item/003132902>. Acesso em: 02 abr. 2025.
3. GRADIO. Gradio – **Build & Share Delightful Machine Learning Apps** [recurso eletrônico]. Disponível em: <https://gradio.app/>. Acesso em: 2 abr. 2025.
4. MAJUMDER, Partha. **Supercharge Your AI: ResNet50 Transfer Learning Unleashed**. Medium, 12 de set. de 2024. Disponível em: <https://medium.com/%40paravisionlab/supercharge-your-ai-resnet50-transfer-learning-unleashed-b7c0e40976c4>. Acesso em: 02 abr. 2025.
5. UNITED STATES DEPARTMENT OF AGRICULTURE. **FoodData Central**. Beltsville: USDA, 2023. Disponível em: <https://fdc.nal.usda.gov/>. Acesso em: 2 abr. 2025.
6. UNIVERSIDADE DE SÃO PAULO. **Tabela Brasileira de Composição de Alimentos – TBCA**. São Paulo: USP, 2023. Disponível em: <https://www.tbca.net.br/>. Acesso em: 2 abr. 2025.
7. ORGANIZAÇÃO DAS NAÇÕES UNIDAS. **Objetivos de Desenvolvimento Sustentável (ODS)**. Brasília: ONU Brasil, 2023. Disponível em: <https://brasil.un.org/pt-br/sdgs>. Acesso em: 2 abr. 2025.